

한국 대중가요 가사의 어휘 다양성과 영어 혼용 비율의 통계적 분석: 2003-2020년 Solid-Liquid 구조 변화

Análisis estadístico de la diversidad léxica y el ratio inglés
en letras de K-pop: cambio de estructura Solid-Liquid 2003-2020

[TODO: Nombre del autor]* [TODO: Nombre del asesor]**

* Autor principal, estudiante de maestría, [TODO: Departamento], [TODO: Universidad] ([TODO: email])

** Autor de correspondencia, [TODO: Cargo], [TODO: Facultad], [TODO: Universidad] ([TODO: email])

요약 (Resumen)

이 연구는 2003년부터 2020년까지 한국 음악 차트 상위권에 오른 대중가요 가사를 대상으로, 어휘 다양성과 영어 혼용 비율의 통계적 변화를 분석한다. **시계열 분석** (시계열 분석 / time series analysis), **스피어만 상관분석** (스피어만 상관 / Spearman correlation) 및 **엔트로피** (엔트로피 / entropy)·**HHI** (HHI / Herfindahl-Hirschman Index) 기반의 **Solid-Liquid 분류** (집중형-분산형 분류 / Solid-Liquid classification)를 활용하여 가사 어휘 구조의 집중형(Solid)·분산형(Liquid) 특성이 연도에 따라 어떻게 변화하는지 살펴본다. 또한 **XGBoost** (XGBoost / XGBoost) 회귀 모형을 통해 영어 비율, 어휘 다양성, 반복률 등의 언어적 변수가 차트 순위를 설명하는 추가적인 통계적 유의성을 검증한다. 분석 결과, 영어 혼용 비율은 2003년 이후 구조적으로 증가하는 추세이며, 어휘 분산 구조(Liquid)는 특정 연도군에 집중되는 경향이 있음을 확인하였다. 이 연구는 한국어 텍스트 코퍼스를 활용한 시계열 언어 통계 분석의 새로운 프레임워크를 제시한다.

주요어: 대중가요 가사, 어휘 다양성, 영어 혼용, 엔트로피, HHI, Solid-Liquid, 시계열 분석, XGBoost, 차트 순위

Abstract

This study conducts a statistical analysis of the lexical diversity and English-mixing ratio in Korean popular music (K-pop) lyrics spanning from 2003 to 2020. Using a self-constructed longitudinal corpus derived from Korean music chart data, we examine temporal changes in vocabulary concentration through entropy and Herfindahl-Hirschman Index (HHI) metrics, classifying each year as exhibiting a concentrated (Solid) or dispersed (Liquid) lexical structure. Additionally, Spearman correlation and XGBoost regression are applied to assess the statistical relationship between linguistic variables — English ratio, lexical diversity, and repetition rate — and chart ranking positions. Results indicate a structurally increasing trend in English mixing since 2003, and a Liquid lexical structure concentrated in specific year clusters. This study proposes a new time-series linguistic framework for statistical analysis of Korean text corpora.

Keywords: K-pop lyrics, lexical diversity, English mixing, entropy, HHI, Solid-Liquid, time series, XGBoost, chart ranking

I. Introducción

La música popular coreana (K-pop) ha experimentado una transformación lingüística notable durante las dos últimas décadas. Mientras que en los primeros años del siglo XXI las letras se componían predominantemente en coreano, a partir de mediados de la década de 2000 comenzó a observarse una incorporación creciente de vocabulario en inglés, un fenómeno que coincide con la expansión internacional del Hallyu (한류) (Kim & Ryoo, 2007; Jung, 2014).

Sin embargo, esta transformación lingüística no ha sido estudiada de forma cuantitativa y longitudinal desde una perspectiva estadística formal. La mayor parte de la literatura existente aborda el fenómeno del code-mixing en el K-pop desde enfoques cualitativos o sobre corpus reducidos y acotados temporalmente (Moody & Matsumoto, 2011; Lee, 2004). Existe, por tanto, un vacío de investigación en el análisis estadístico de la evolución temporal de la estructura léxica de las letras de K-pop a gran escala.

Este estudio busca cubrir dicho vacío mediante el análisis de un corpus longitudinal propio de letras de canciones que alcanzaron las posiciones superiores del ranking mensual en el período 2003–2020, un total de [TODO: N canciones] con [TODO: N tokens]. Se proponen tres preguntas de investigación:

1. ¿Existe una tendencia estadísticamente significativa de aumento del ratio inglés en las letras de K-pop durante el período 2003–2020?
2. ¿Cómo varía la estructura léxica (Solid vs. Liquid) a lo largo de los años analizados, medida a través de entropía y HHI?
3. ¿En qué medida las variables lingüísticas (ratio inglés, diversidad léxica, tasa de repetición) se asocian estadísticamente con la posición en el ranking mensual?

II. Marco teórico

2.1 Code-mixing y contacto lingüístico en la música popular

El **code-mixing** (코드 혼용 / code-mixing) es el fenómeno por el cual hablantes alternan entre dos o más lenguas dentro de un mismo texto o discurso (Myers-Scotton, 1993). En el contexto de la música popular, el uso de inglés en letras de otros idiomas ha sido documentado en múltiples mercados — japonés, español, sueco — como estrategia de posicionamiento y ampliación de audiencias (Moody & Matsumoto, 2011). En el caso del K-pop, Lee (2004) identificó patrones recurrentes de alternancia coreano-inglés en letras de grupos de idol de la década de 1990, y estudios posteriores han relacionado este fenómeno con la globalización activa del género (Jung, 2014).

2.2 Diversidad léxica y su medición estadística

La **diversidad léxica** (어휘 다양성 / lexical diversity) cuantifica la riqueza del vocabulario empleado en un texto. Las medidas clásicas como la **relación tipo-token** (타입-토큰 비율 / type-token ratio) (TTR) presentan sensibilidad al tamaño del texto (Templin, 1957), por lo que en este estudio se complementa con medidas de distribución:

$$H = - \sum_{i=1}^K p_i \log p_i, \quad H_{norm} = \frac{H}{\log K}, \quad \text{HHI} = \sum_{i=1}^K p_i^2$$

donde K es el número de tipos léxicos distintos y p_i la proporción de cada tipo sobre el total de tokens. Siguiendo la clasificación propuesta por Moon y Pyun (2025), definimos:

$$\text{Liquid} \iff (H_{norm} \geq 0.90) \wedge (\text{HHI} \leq 0.23) \wedge (n_{active} \geq 4)$$

siendo n_{active} el número de categorías léxicas con peso $\geq 10\%$. Cuando no se cumple alguna condición, la estructura se clasifica como Solid.

2.3 Correlación lingüística y posición en el ranking

La relación entre características textuales y popularidad ha sido explorada principalmente en contextos de análisis de sentimiento y recomendación de contenidos (Schedl, 2014). En el ámbito de la música popular, Napier y Shamir (2018) identificaron asociaciones entre simplicidad léxica y mayor desempeño comercial. Este estudio extiende esa línea hacia el mercado coreano y un horizonte temporal de 17 años.

III. Datos y preprocesamiento

3.1 Descripción del corpus

El corpus se construyó a partir de los rankings mensuales de un sitio de música en streaming coreano, recopilando las canciones posicionadas en el top-100 mensual durante el período enero de 2003 – diciembre de 2020, lo que comprende 216 meses de datos.

Característica	Valor
Período	2003.01 – 2020.12
Total de meses	216
Canciones únicas (aprox.)	[TODO: N]
Total de tokens (aprox.)	[TODO: N]
Idioma dominante	Coreano (con presencia de inglés)
Herramienta de análisis morfológico	Kiwipiepy (Kiwi)

Table 1: Descripción general del corpus

Para el análisis morfológico se empleó `kiwipiepy` (Kiwi), analizador de morfemas del coreano basado en modelos de lenguaje, que permite identificar sustantivos (etiquetas NN*), verbos y adjetivos de forma robusta incluso en textos coloquiales como letras de canciones.

3.2 Variables construidas

Variable	Descripción	Tipo
english_ratio	Proporción de tokens en inglés sobre el total	Continua [0,1]
entropy	Entropía de la distribución de sustantivos	Continua ≥ 0
HHI	Índice Herfindahl-Hirschman léxico	Continua (0,1]
H_norm	Entropía normalizada ($H/\log K$)	Continua [0,1]
n_active	Categorías léxicas con peso $\geq 10\%$	Discreta
repetition_rate	Proporción de tokens repetidos en la canción	Continua [0,1]
rank	Posición en el ranking mensual (1–100)	Discreta
solid_liquid	Clasificación binaria Solid / Liquid	Categórica

Table 2: Variables del análisis

3.3 Preprocesamiento

Se aplicó un preprocesamiento mínimo sobre las letras crudas: eliminación de caracteres especiales y URLs, normalización Unicode, y separación de tokens coreanos e ingleses mediante expresiones regulares ($[\square-\square]^+$ para coreano, $[a-zA-Z]^+$ para inglés). No se eliminaron palabras vacías del coreano con el fin de preservar la estructura rítmica y de repetición característica de las letras.

IV. Metodología

4.1 Análisis de tendencia temporal del ratio inglés

Para verificar si el ratio inglés presenta una tendencia estadísticamente significativa durante el período analizado, se aplica la **prueba de Mann-Kendall** (Mann-Kendall 검정 / Mann-Kendall test), un test no paramétrico para tendencias monotónicas en series temporales (Mann, 1945; Kendall, 1975). La estadística de prueba S se define como:

$$S = \sum_{k=1}^{n-1} \sum_{j=k+1}^n \text{sgn}(x_j - x_k)$$

donde $\text{sgn}(\cdot)$ es la función signo. La hipótesis nula H_0 es la ausencia de tendencia monotónica.

4.2 Clasificación Solid–Liquid por año

Para cada año y del período analizado se calcula la distribución de tokens léxicos en K categorías semánticas derivadas mediante análisis de frecuencias de sustantivos. A partir de dicha distribución se obtienen $H_{\text{norm}}(y)$, $\text{HHI}(y)$ y $n_{\text{active}}(y)$, y se clasifica el año como Solid o Liquid según el criterio de la sección 2.2.

4.3 Correlación ranking-variables lingüísticas

La relación entre las variables lingüísticas y la posición en el ranking se cuantifica mediante la **correlación de Spearman** (스피어만 상관계수 / Spearman rank correlation):

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

donde d_i es la diferencia de rangos entre las dos variables para la observación i . Se reportan los coeficientes r_s y sus p -valores correspondientes con corrección de Bonferroni para comparaciones múltiples.

4.4 Modelo XGBoost: variables lingüísticas como predictores del ranking

Para evaluar el poder explicativo conjunto de las variables lingüísticas se construyen dos modelos de regresión XGBoost (Chen & Guestrin, 2016), siguiendo el esquema de Kim y Pyun (2026):

- **Modelo A (referencia):** solo variables temporales (año, mes, tendencia).
- **Modelo B (ampliado):** variables temporales + english_ratio, H_norm, HHI, repetition_rate.

La mejora en poder explicativo se evalúa comparando el **coeficiente de determinación ajustado** (수정된 결정계수 / adjusted R^2) y el **RMSE** (RMSE / Root Mean Squared Error). Se reporta además la importancia de cada variable (feature importance) para identificar cuáles contribuyen más a la explicación del ranking.

V. Resultados

5.1 Tendencia temporal del ratio inglés (2003–2020)

[TODO: Insertar figura: serie de tiempo del ratio inglés por año con línea de tendencia.]

La prueba de Mann-Kendall sobre la serie anual del ratio inglés arrojó [TODO: estadístico $S = X$, $p = X$], [TODO: confirmando / no confirmando] la existencia de una tendencia creciente estadísticamente significativa en el período analizado.

Estadístico	Valor	Interpretación
Tau de Kendall (τ)	[TODO: X.XX]	[TODO: tendencia positiva/negativa]
p -valor	[TODO: X.XX]	[TODO: significativo / no significativo]
Pendiente de Sen	[TODO: X.XX]	Cambio promedio anual en ratio inglés

Table 3: Resultado de la prueba de Mann-Kendall sobre el ratio inglés anual

5.2 Clasificación Solid–Liquid por año

[TODO: Insertar tabla: año, entropy, H_norm, HHI, n_active, clasificación.]

[TODO: Insertar figura: gráfico de radar o barras apiladas por año mostrando la distribución léxica y la clasificación Solid/Liquid.]

Los resultados muestran que [TODO: X de 18 años] se clasificaron como Liquid y [TODO: X] como Solid. Los años clasificados como Liquid se concentran en [TODO: describir período: ej. 2012-2016], coincidiendo con [TODO: fenómeno contextual, ej. boom del Hallyu internacional].

5.3 Correlación ranking-variables lingüísticas

Variable	r_s	p -valor	Interpretación
english_ratio	[TODO: X.XX]	[TODO: X.XX]	[TODO:]
H_norm	[TODO: X.XX]	[TODO: X.XX]	[TODO:]
HHI	[TODO: X.XX]	[TODO: X.XX]	[TODO:]
repetition_rate	[TODO: X.XX]	[TODO: X.XX]	[TODO:]

Table 4: Correlaciones de Spearman entre variables lingüísticas y ranking

5.4 Comparación de modelos XGBoost

Modelo	Adjusted R^2	RMSE	Variables
Modelo A (referencia)	[TODO: X.XX]	[TODO: X.XX]	Temporales
Modelo B (ampliado)	[TODO: X.XX]	[TODO: X.XX]	Temporales + lingüísticas
Diferencia	[TODO: +X.X pp]	[TODO: -X.X%]	

Table 5: Comparación de poder explicativo: Modelo A vs. Modelo B

[TODO: Insertar figura: importancia de variables (feature importance) del Modelo B.]

VI. Implicaciones y trabajo futuro

Este estudio presenta un **corpus longitudinal** (종단 코퍼스 / longitudinal corpus) de letras de K-pop 2003–2020 y propone un marco estadístico para analizar su evolución léxica que combina análisis de tendencia temporal, clasificación Solid–Liquid basada en entropía y HHI, y modelización explicativa mediante XGBoost.

Los resultados contribuyen a la estadística aplicada de textos en tres dimensiones: (1) verificación empírica de la tendencia de aumento del inglés en la música popular coreana, con prueba de significancia formal; (2) demostración de que la estructura léxica varía entre años de forma cuantificable y clasificable; y (3) evidencia del poder explicativo adicional de variables lingüísticas sobre la posición en el ranking.

Como trabajo futuro se propone: incorporar análisis de tópicos (LDA) para definir ejes semánticos formales al estilo de Moon y Pyun (2025); ampliar el modelo XGBoost con variables de interacción temporal (gradiente año a año) siguiendo a Kim y Pyun (2026); y explorar la relación entre cambios léxicos y contexto sociocultural (lanzamientos internacionales, eventos políticos).

Referencias

- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794. <https://doi.org/10.1145/2939672.2939785>
- Jung, S. (2014). K-pop, Indonesian fandom, and social media. Transformative Works and Cultures, 17. <https://doi.org/10.3983/twc.2014.0541>

- Kendall, M. G. (1975). *Rank Correlation Methods* (4th ed.). Griffin.
- Kim, C., & Pyun, J. (2026). 해외 기상 데이터를 활용한 집중호우 설명 모형의 개선: 대안 데이터 활용의 관점에서. **[TODO: [Revista y volumen por confirmar]]**.
- Lee, J. (2004). Linguistic hybridization in K-pop: Discourse of self-assertion and resistance. *World Englishes*, 23(3), 429–450.
- Mann, H. B. (1945). Nonparametric tests against trend. *Econometrica*, 13(3), 245–259.
- Moody, A., & Matsumoto, Y. (2011). Don't touch my moustache: Language blending and code ambiguation by two J-pop artists. *Asian Englishes*, 14(1), 4–33.
- Moon, J., & Pyun, J. (2025). 리뷰 텍스트 임베딩 기반 소비자 가치측 분류-Entropy·HHI기반 Solid-Liquid 소비유형. *글로벌경영학회지*, 22(X), 1–1. <https://doi.org/10.38115/asgba.2025.22.x.x>
- Myers-Scotton, C. (1993). *Duelling Languages: Grammatical Structure in Codeswitching*. Clarendon Press.
- Napier, K., & Shamir, L. (2018). Quantitative sentiment analysis of lyrics in popular music. *Journal of Popular Music Studies*, 30(4), 161–176.
- Schedl, M. (2014). Leveraging microblogs for spatiotemporal music information retrieval. *Proceedings of the 36th European Conference on IR Research*, 796–801.
- Templin, M. (1957). *Certain Language Skills in Children*. University of Minnesota Press.

Glosario de términos técnicos

한국어	Español	English	Nota
대중가요 가사	letras de música popular	popular song lyrics	K-pop en contexto
어휘 다양성	diversidad léxica	lexical diversity	medida con TTR, entropía
영어 혼용	mezcla de inglés	English mixing / code-mixing	tokens en inglés sobre total
엔트로피	entropía	entropy	$H = -\sum p_i \log p_i$
정규화 엔트로피	entropía normalizada	normalized entropy	$H_{norm} = H / \log K$
허핀달-허쉬만 지수	índice Herfindahl-Hirschman	HHI	concentración léxica
집중형	tipo concentrado	Solid	un eje léxico dominante
분산형	tipo disperso	Liquid	varios ejes léxicos activos
활성 범주 차트 순위	categoría activa posición en el ranking	active category chart ranking	peso $\geq 10\%$ variable dependiente
시계열 분석	análisis de serie temporal	time series analysis	por año/mes
Mann-Kendall 검정	prueba de Mann-Kendall	Mann-Kendall test	tendencia monotónica
스피어만 상관	correlación de Spearman	Spearman correlation	no paramétrica
형태소 분석	análisis morfológico	morphological analysis	con Kiwipiepy
명사	sustantivo	noun	etiqueta NN* en Kiwi
반복률	tasa de repetición	repetition rate	tokens repetidos / total
기준 모형	modelo de referencia	baseline model	solo variables temporales
확장 모형	modelo ampliado	extended model	+ variables lingüísticas
변수 중요도	importancia de variables	feature importance	salida de XG-Boost
수정된 결정계수	coef. determinación ajustado	adjusted R^2	penaliza complejidad
한류	ola coreana	Korean Wave / Hallyu	fenómeno cultural global